PROGETTO FINALE · NOVEMBRE 2026

ScoutEdge Analytics

Un assistente AI per il reparto Data Science & Client Success

Risponde consultando il manuale interno o analizza i dati di scouting e sceglie da solo quale strada prendere.

Demo online: francodesc-scoutedge-analytics.hf.space



Francesco Benassi · Master «AI e Agenti AI per il Business», Start2Impact / UniMarconi

ScoutEdge Analytics è un'azienda immaginaria

LO SCENARIO

Il problema: due bisogni, due strumenti diversi

Le informazioni sono nei documenti

Piani di abbonamento, metodologia del rating, procedura di pulizia dei dati, SLA ed escalation, FAQ: tutto è nel manuale interno del reparto, ma va cercato a mano.

I numeri sono nei dati

Le osservazioni di scouting sono in un file CSV con anomalie reali: righe duplicate, club scritti in 74 modi diversi, date in formati misti. Per una media o una classifica bisogna prima pulirlo, poi scrivere codice.

Servono strumenti e competenze diverse: ogni domanda costa tempo a chi deve decidere.

LA SOLUZIONE

Una sola chat, tre strade possibili

Regole, procedure, metodologia

«Qual è il tempo di prima risposta per una richiesta ad alta priorità?»

→ ricerca nel manuale interno

Numeri, classifiche, grafici

«Quali sono i 10 giocatori con il valore di mercato attuale più alto? Mostrami anche un grafico.»

→ analisi del dataset in Python

Entrambe le cose

«Quali metriche contano di più per i difensori centrali? Poi mostrami i 3 migliori.»

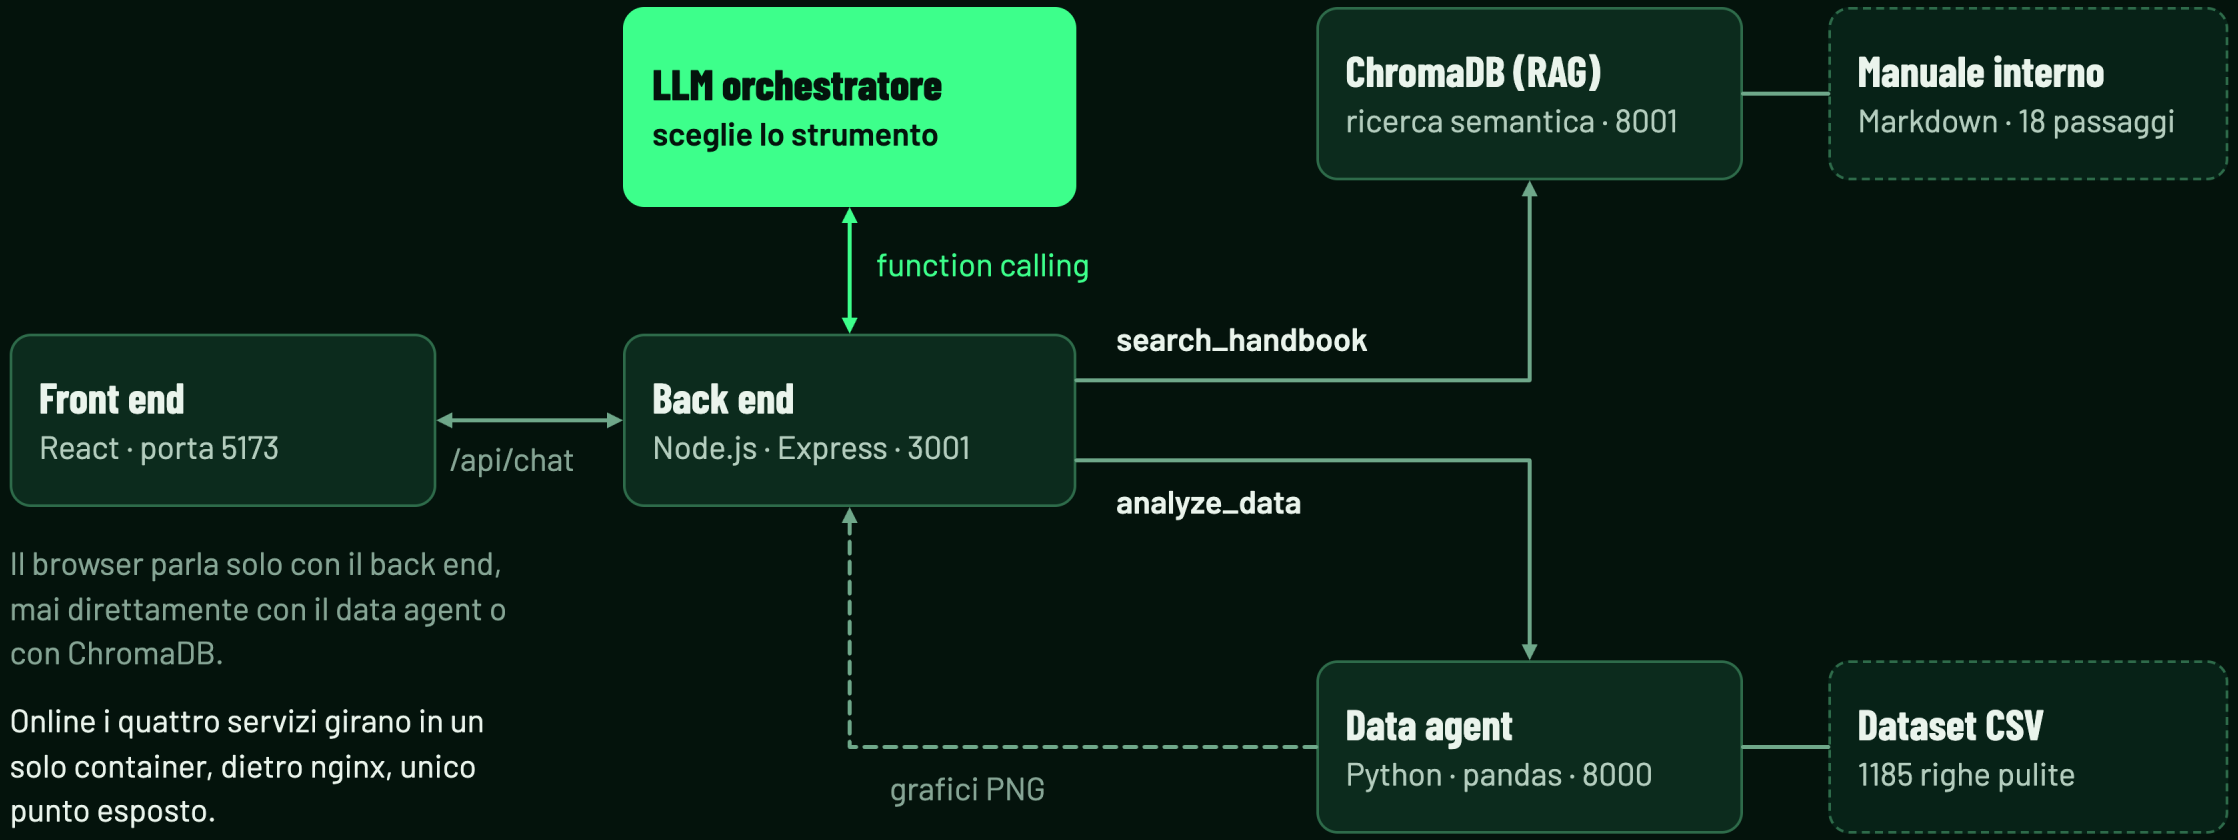
→ prima il manuale, poi i dati

IL VALORE PER IL REPARTO

- ✓ Ogni risposta indica la fonte usata
- ✓ Analisi senza scrivere codice
- ✓ Memoria della conversazione
- ✓ Se una fonte non risponde, lo dichiara

ARCHITETTURA · QUATTRO SERVIZI

L'LLM al centro delle decisioni



Il browser parla solo con il back end, mai direttamente con il data agent o con ChromaDB.

Online i quattro servizi girano in un solo container, dietro nginx, unico punto esposto.

L'LLM COME SNODO DECISIONALE

Come l'assistente sceglie la strada

1. Solo numeri o grafici
→ analyze_data

2. Solo regole o metodologia
→ search_handbook

3. Entrambe le cose, chieste in modo esplicito
→ prima il manuale, poi i dati

4. Fuori ambito o saluto
→ nessuno strumento

```
> back-end@1.0.0 start
> node src/index.js

Back end in ascolto su http://localhost:3001
[tool] search_handbook {"query":"tempo di prima risposta per richieste ad alta priorità"}
[chat] sessione=763890d4 tool=[search_handbook] durata=5848ms esito=ok
[tool] analyze_data {"question":"Quali sono i 10 giocatori con il valore di mercato attuale più alt
o?","chart":true}
[chat] sessione=64083ee5 tool=[analyze_data] durata=14376ms esito=ok
[tool] search_handbook {"query":"metriche più importanti per i difensori centrali"}
[tool] analyze_data {"question":"Mostrami i 3 difensori centrali con il duels_won_pct attuale più a
lto.","chart":false}
[chat] sessione=fc6d4532 tool=[search_handbook,analyze_data] durata=9851ms esito=ok
```

Il log del back end durante la demo:

- SLA → solo il manuale
- Top 10 → solo i dati, con il grafico
- Difensori centrali → entrambi, in sequenza

Ciclo ReAct scritto a mano, al massimo 4 giri di scelta degli strumenti. Il data agent non vede la chat: riceve una domanda riscritta e completa.

DATI E KNOWLEDGE BASE

Due fonti costruite per essere coerenti

Il dataset delle osservazioni

1208 → 1185
righe, dopo aver tolto 23 duplicati

130
giocatori, identificati sempre da player_id

25
club, scritti in 74 modi diversi nel file grezzo

3
stagioni, dal 2023/24 al 2025/26

Pulizia deterministica nel codice, non affidata all'LLM. Schema dei dati controllato all'avvio: se qualcosa non torna il servizio non parte, e tutte le violazioni arrivano in un solo errore.

Il manuale interno (knowledge base)

8
sezioni, da chi siamo alle FAQ

18
passaggi indicizzati in ChromaDB

È un file Markdown: testo semplice, i cui titoli servono a dividerlo in passaggi per la ricerca.

Allineato ai dati: la procedura di pulizia descritta nella sezione 6 è quella che il codice applica, e il glossario spiega le colonne del CSV.

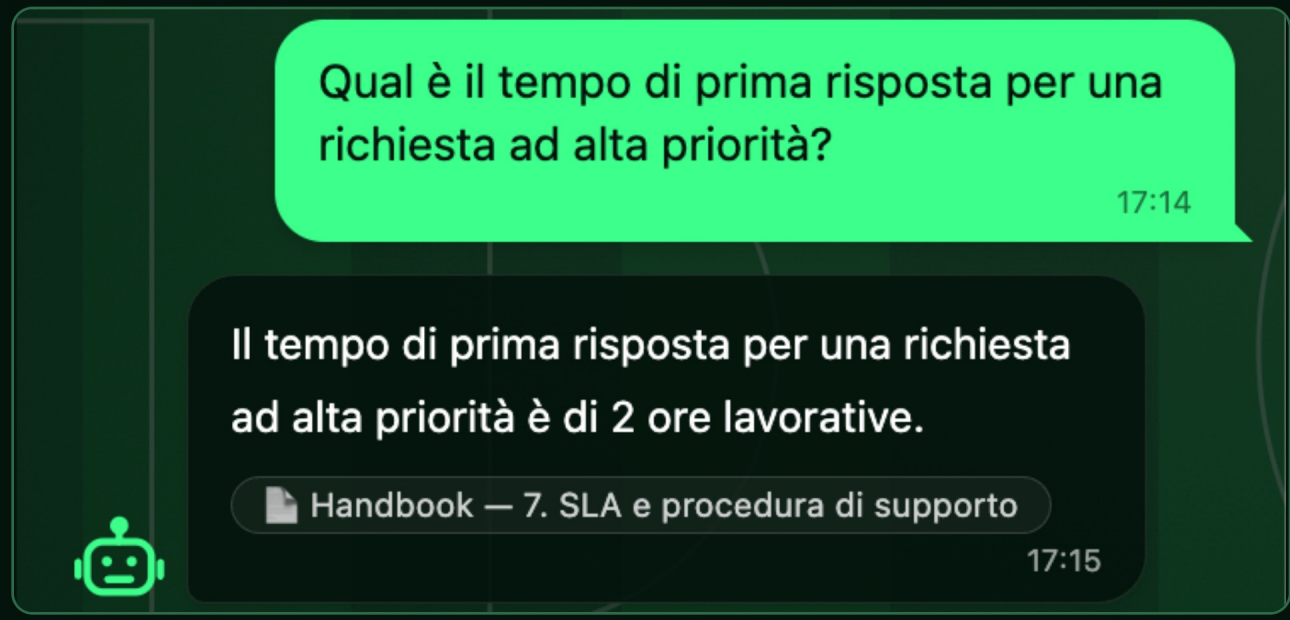
DEMO 1 · RISPOSTA DAL MANUALE

Per le regole, la risposta arriva dal manuale

1. L'LLM riconosce una domanda sulle procedure e chiama solo search_handbook.

2. ChromaDB trova i passaggi più vicini alla domanda; al modello arrivano solo quelli abbastanza pertinenti (distanza fino a 0,60 e vicina a quella del passaggio migliore).

3. La risposta è «2 ore lavorative»; sotto compare l'etichetta della sezione usata, «7. SLA e procedura di supporto».



DEMO 2 · ANALISI DEI DATI CON GRAFICO

Per i numeri, l'analisi passa al data agent

1. L'LLM chiama analyze_data e passa la richiesta del grafico come parametro (chart: true).

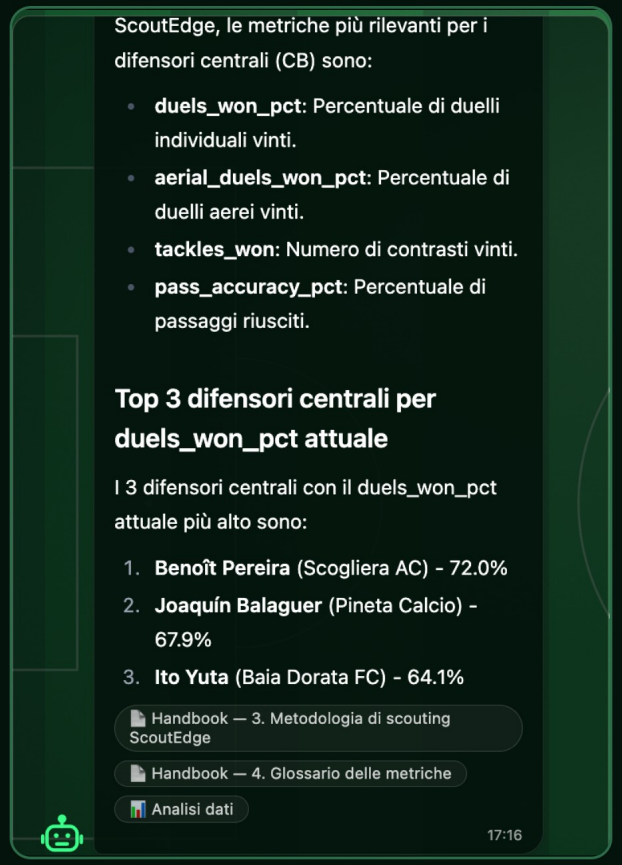
2. Il data agent scrive ed esegue codice pandas sul dataset già pulito e genera il grafico.

3. Al primo posto c'è il giocatore 5, Sato Jun, con 18.680.000 €. Il grafico compare nella risposta e nel pannello laterale, dove si può ingrandire o scaricare.



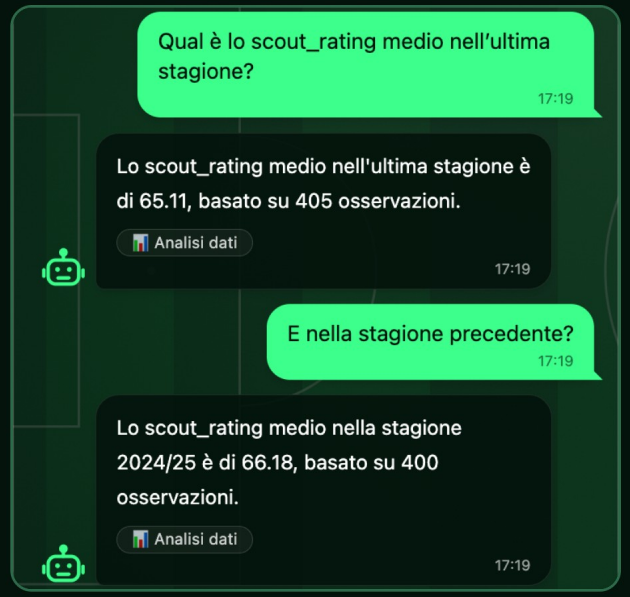
DEMO 3 · DOMANDA IBRIDA E MEMORIA

Una risposta con due strumenti e una chat che ricorda



Prima il manuale, poi i dati

Le metriche per i difensori centrali vengono dal manuale (sezioni 3 e 4); poi i dati indicano i 3 CB con il duels_won_pct attuale più alto: 120 Pereira (72,0), 122 Balaguer (67,9) e 6 Ito Yuta (64,1).



Memoria della conversazione

«E nella stagione precedente?» si capisce solo grazie alla domanda di prima: l'assistente la completa con la stagione 2024/25.

Risultati: 65,11 su 405 osservazioni nell'ultima stagione, poi 66,18 su 400.

SFIDE TECNICHE · 1 DI 4

Pulizia dei dati e calcoli corretti

Dati sporchi

COSA È EMERSO

74 grafie diverse per 25 club, nomi giapponesi in kanji e titoli come «Dr.» o «MBA» nei nomi di 12 giocatori (113 righe): questi ultimi sono emersi solo con una scansione completa del file.

SOLUZIONE

Pulizia deterministica nel codice, eseguita all'avvio, con uno schema controllato e un riepilogo delle correzioni che l'assistente può citare.

Una media sbagliata

COSA È EMERSO

Lo scout_rating medio dell'ultima stagione risultava 65,21 invece di 65,11: veniva calcolato sull'ultima osservazione di ogni giocatore (130 righe) e non sulle 405 della stagione.

SOLUZIONE

Il prompt distingue le domande su un periodo da quelle sullo stato attuale; il valore corretto è fissato nei test.

SFIDE TECNICHE · 2 DI 4

I grafici e l'integrazione tra agenti

Grafici lasciati al modello

COSA È EMERSO

Il modello salvava i grafici a modo suo e poteva annunciarne uno che non esisteva; gli assi dei valori di mercato comparivano in notazione 1e7.

SOLUZIONE

Il grafico si richiede con un parametro e viene salvato solo dallo strumento; la nota «grafico generato» è scritta dal codice; gli assi hanno i separatori delle migliaia.

Due agenti che non si capivano

COSA È EMERSO

Per la domanda sui giocatori 33 e 70, l'orchestratore scrive al data agent «giocatore con ID 70». Con questa forma il data agent saltava il controllo delle osservazioni nello stesso giorno: 19 risposte corrette su 33.

SOLUZIONE

La regola che attiva il controllo ora elenca anche le altre forme con cui si può indicare un giocatore: 30 risposte corrette su 30, senza regressioni sugli altri casi.

Il metodo: prima si traccia, poi si corregge

Prima di toccare il prompt, uno script mostra il codice eseguito dal data agent e l'output che ha ricevuto. Per i casi difficili il criterio di arresto è deciso in anticipo, e una modifica che peggiora altri casi viene tolta.

SFIDE TECNICHE · 3 DI 4

La scelta della piattaforma per la demo online

Piattaforma prevista a pagamento

Gli Space Docker di Hugging Face richiedono il piano PRO dall'8 luglio 2026. I piani gratuiti di altri servizi offrono 256–512 MB di memoria e poca CPU.

Prima misurare, poi scegliere

Il container in funzione usa tra 212 e 256 MB. Poi un piano gratuito simulato in locale (0,1 CPU, 512 MB).

La decisione

Il collo di bottiglia è la CPU, non il codice: piano gratuito scartato. Scelta: Hugging Face PRO (9 $ al mese), con il container pronto in circa 20 secondi.

Avvio simulato: 2 minuti e 29 secondi, con `docker run --cpus=0.1 --memory=512m`



Indicizzazione 28 s — **Data agent 91 s, di cui 79 s solo per caricare Python e le librerie** — Back end 28 s

Chroma (1,7 s, il tratto chiaro iniziale) e nginx (0,5 s, quello finale) durano pochi istanti.

Sullo Space di Hugging Face (2 CPU): pronto in circa 20 secondi

SFIDE TECNICHE · 4 DI 4

Due richieste insieme nella demo pubblica

Il problema: uno stato condiviso da tutto il processo

FastAPI esegue le analisi in un pool di thread: due richieste possono eseguire codice generato insieme, nello stesso processo.

- **A** sostituisce plt.savefig con una funzione vuota
- **B** salva come «originale» la funzione vuota di A
- **A** finisce e rimette la funzione vera
- **B** finisce e rimette la funzione vuota: da qui nessun grafico fino al riavvio

La soluzione: un lock attorno all'esecuzione

Serializza solo l'esecuzione del codice generato, di norma sotto il secondo; la chiamata al modello resta in parallelo. Nessuna nuova dipendenza.

ALTERNATIVE SCARTATE

API a oggetti di matplotlib: non basta, perché restano globali anche sys.stdout, le opzioni di pandas e seaborn; cambierebbero strumento e prompt.

Processi separati: perdono le variabili tra le chiamate e ricaricano le librerie; sarebbe un cambio di architettura.

17 su 20
giri falliti sul codice vecchio: il test è stato scritto prima della correzione

20 su 20
giri passati con il lock; il test gira con gli altri del data agent

Online
due domande con grafico in parallelo: due grafici corretti. Prova ripetuta sulla versione finale della demo.

TEST E AFFIDABILITÀ

Test automatici e valutazione con il modello reale

437

test automatici, senza modello né chiave OpenAI

136 data agent · pytest

225 back end · node:test

76 front end · Vitest

Eseguiti dall'integrazione continua a ogni push: tre job paralleli, circa un minuto.

Valutazione con il modello reale

13 domande (16 turni), ripetute N volte, ognuna in una sessione nuova. Il voto lo dà il codice, non un altro modello: cerca nella risposta i numeri attesi in qualsiasi formato (18.680.000 o 18,680,000), senza approssimazioni, e controlla a parte se ha scelto gli strumenti giusti: manuale, dati, entrambi o nessuno.

Corsa	N	Numeri corretti	Strumenti corretti
Prima corsa completa, non salvata	5	78 su 80	non registrato
Corsa completa	5	80 su 80	80 su 80
Difensori centrali	20	20 su 20	20 su 20

Un limite resta dichiarato. Sui tre difensori centrali l'errore è sempre lo stesso: compare solo Pereira. È uno dei due turni sbagliati della prima corsa, che si conta; 25 risposte corrette su 25 nelle corse salvate non bastano a dire che non c'è più.

Prove a mano ancora valide: demo 4 su 4 in locale e online, contratto API 23 su 23, servizio spento 3 su 3.

PRESTAZIONI · BENCHMARK

Pandas basta fino a 60 volte i dati attuali

Dataset sintetici da 1 a 1000 volte il file reale, con le stesse anomalie; mediana di 5 ripetizioni. Regola fissata prima di misurare: oltre soglia se una domanda supera 1 s, il dataframe 50 MB, il picco dell'avvio 250 MB o l'avvio 10 s; si cambia solo con un miglioramento di almeno 2 volte.

Dimensione	Righe pulite	Avvio	Dataframe	Picco all'avvio	Domanda più lenta
1×	1.185	0,13 s	0,8 MB	7,5 MB	1,5 ms
10×	11.850	0,77 s	8,3 MB	34,2 MB	3,9 ms
30×	35.550	2,21 s	25,0 MB	80,1 MB	10,2 ms
60×	71.100	4,39 s	50,0 MB	142,0 MB	18,7 ms
100×	118.500	7,25 s	83,3 MB	218,0 MB	35,3 ms
1000×	1.185.000	73,5 s	832,6 MB	1.646 MB	454,6 ms

La decisione

Nessuna modifica al codice. Il primo limite è la memoria, non il tempo: a 1000× la domanda più lenta richiede 455 ms.

DuckDB conviene tra 100× e 1000×. A 100× su Parquet migliora la memoria solo di 1,65 volte; intorno a 170× per estrapolazione, una stima.

Prima, gli interventi più economici: liberare il dataframe grezzo, che resta in memoria, e una pulizia vettoriale al posto di .apply.

In arancione le misure oltre soglia. 90 confronti pandas/DuckDB, risultati tutti uguali. Una sola macchina (Apple M1), più veloce dello Space.

SICUREZZA

Segreti protetti e difese a strati

Nessuna chiave nel codice

Le chiavi API stanno solo nei file .env, esclusi da git, o tra i secret dello Space; ogni servizio ha un .env.example senza valori. Verificato sul clone pulito.

La demo online

Un solo punto esposto

nginx serve l'interfaccia e inoltra al back end solo /api/ e /charts/; il resto risponde 404.

Limite di frequenza

20 richieste per IP e 100 in totale ogni 15 minuti, poi risposta 429.

IP vero del client

Ricavato con trust proxy e verificato: un indirizzo falsificato dal client viene ignorato.

Input

Messaggi fino a 2000 caratteri, corpo fino a 10 kb.

Rete

Data agent e ChromaDB raggiungibili solo in locale.

Tempi

Timeout di 90, 120 e 130 s sui tre tratti.

Grafici

Nomi validati in tre punti contro il path traversal.

Errori

Nessun dettaglio interno arriva al browser.

Interfaccia

Markdown senza HTML grezzo né immagini.

Intestazioni

Nessuna X-Powered-By, verificato da un test.

Integrazione continua

Permessi di sola lettura, nessun secret.

LIMITI DICHIARATI

Limiti noti e cosa servirebbe in produzione

Il limite principale: la demo è protetta, ma il codice non ha una sandbox

Il data agent esegue codice Python scritto dall'LLM: una prompt injection potrebbe diventare codice eseguito, online nello stesso processo che conosce la chiave OpenAI. Mitigazioni: chiave dedicata con un tetto di spesa mensile e revocabile, limite di frequenza, regola che vieta all'orchestratore di inoltrare codice agli strumenti (solo un primo filtro).

Altri limiti

- Risposte probabilistiche: alcune domande sui dati danno esiti variabili
- Importi nel testo in notazione anglosassone (18,680,000)
- Stagioni del dataset scritte nel prompt e nello schema dei dati
- Sessioni in memoria, senza un tetto massimo
- Un codice generato che non termina tiene il lock: le altre analisi ricevono «servizio occupato» dopo 30 s
- Valutazione automatica fuori dall'integrazione continua, perché costa token

In produzione servirebbero

- Una sandbox isolata per eseguire il codice, senza rete né accesso al disco
- Autenticazione degli utenti
- Sessioni persistenti e con limiti

Il limite di frequenza della demo è una protezione di base: non sostituisce l'autenticazione.

IN SINTESI

Una chat, due fonti e un LLM che decide quale usare

Risposte dal manuale con la fonte citata, analisi dei dati con grafici e un sistema che dice chiaramente quando una fonte non è disponibile.

DEMO ONLINE

francodesc-scoutedge-analytics.hf.space

Dopo 48 ore senza visite la demo va in pausa: la prima apertura richiede circa 30 secondi.

REPOSITORY GITHUB

github.com/FranCodesc/scoutedge-analytics

Codice dei tre servizi, dataset e manuale, README con l'avvio rapido; installazione, deploy, test, sicurezza e decisioni in docs/.