PROGETTO FINALE · OTTOBRE 2026

ScoutEdge Analytics

Un assistente AI per il reparto Data Science & Client Success

Risponde consultando il manuale interno o analizza i dati di scouting e sceglie da solo quale strada prendere.

Demo online: francodesc-scoutedge-analytics.hf.space



Francesco Benassi · Master «AI e Agenti AI per il Business», Start2Impact / UniMarconi

ScoutEdge Analytics è un'azienda immaginaria

LO SCENARIO

Il problema: due bisogni, due strumenti diversi

Le informazioni sono nei documenti

Piani di abbonamento, metodologia del rating, procedura di pulizia dei dati, SLA ed escalation, FAQ: tutto è nel manuale interno del reparto, ma va cercato a mano.

I numeri sono nei dati

Le osservazioni di scouting sono in un file CSV con anomalie reali: righe duplicate, club scritti in 74 modi diversi, date in formati misti. Per una media o una classifica bisogna prima pulirlo, poi scrivere codice.

Servono strumenti e competenze diverse: ogni domanda costa tempo a chi deve decidere.

LA SOLUZIONE

Una sola chat, tre strade possibili

Regole, procedure, metodologia

«Qual è il tempo di prima risposta per una richiesta ad alta priorità?»

→ ricerca nel manuale interno

Numeri, classifiche, grafici

«Quali sono i 10 giocatori con il valore di mercato attuale più alto? Mostrami anche un grafico.»

→ analisi del dataset in Python

Entrambe le cose

«Quali metriche contano di più per i difensori centrali? Poi mostrami i 3 migliori.»

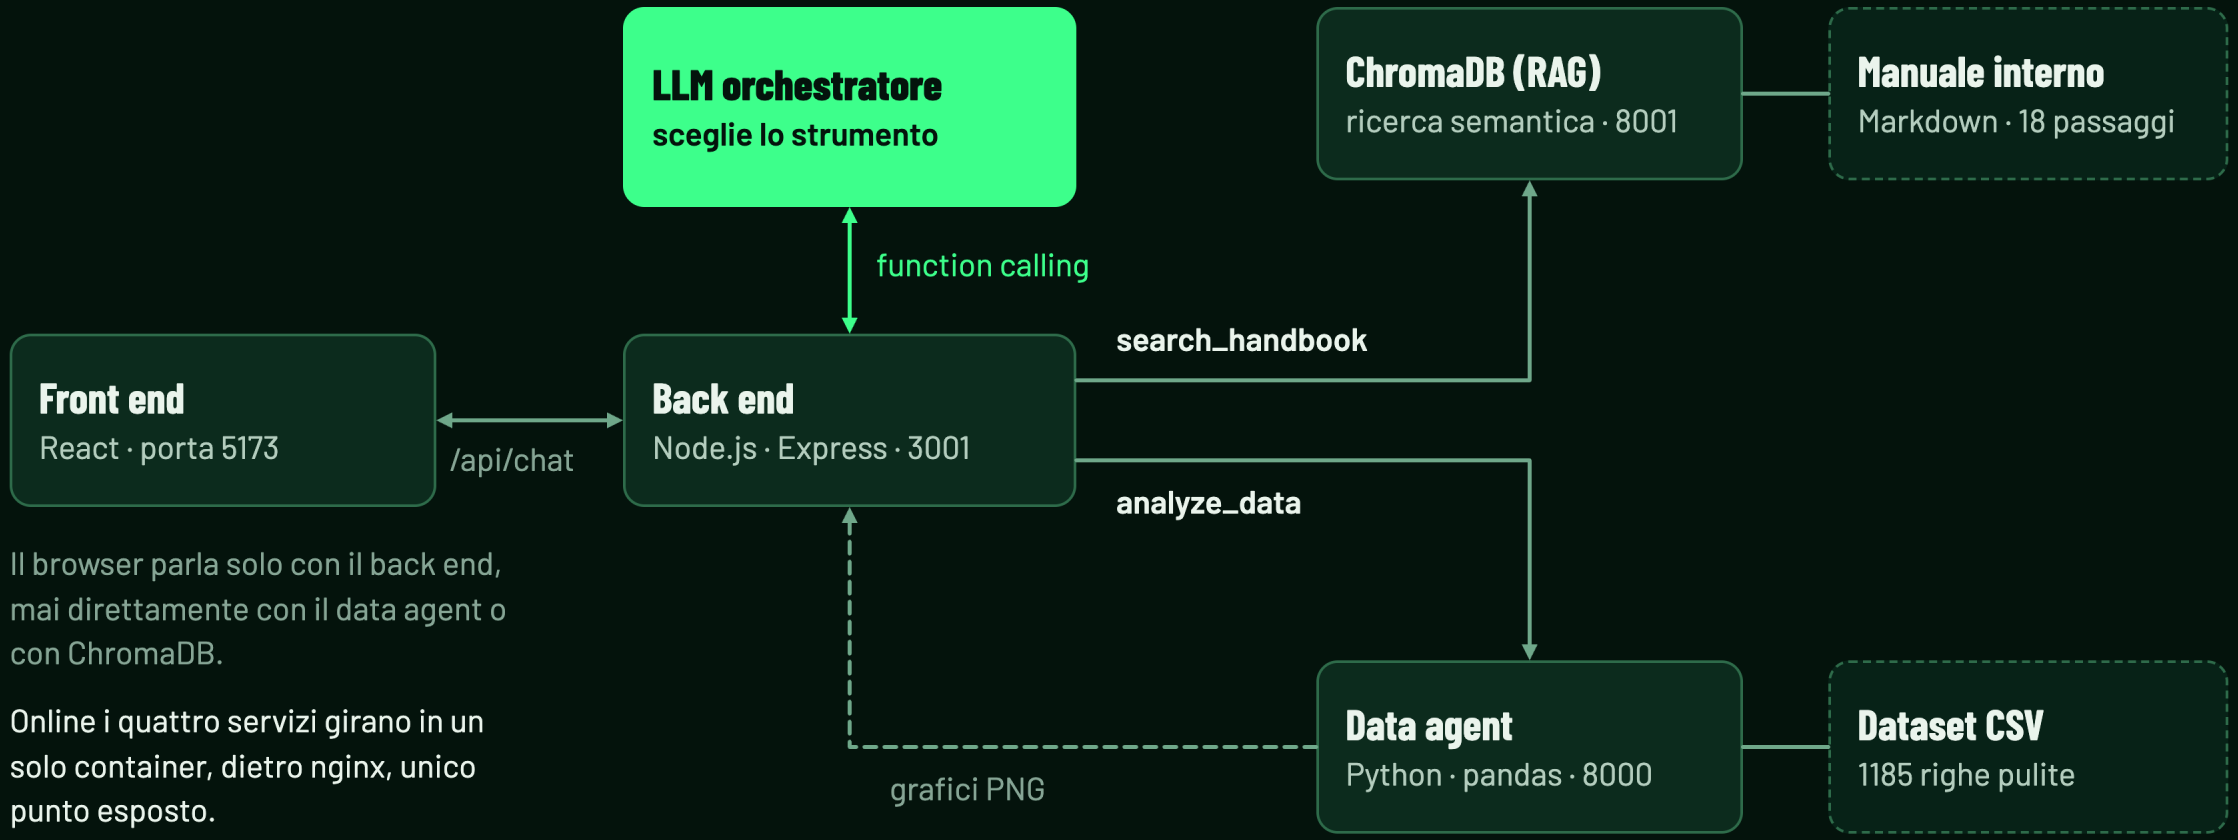
→ prima il manuale, poi i dati

IL VALORE PER IL REPARTO

- ✓ Ogni risposta indica la fonte usata
- ✓ Analisi senza scrivere codice
- ✓ Memoria della conversazione
- ✓ Se una fonte non risponde, lo dichiara

ARCHITETTURA · QUATTRO SERVIZI

L'LLM al centro delle decisioni



Il browser parla solo con il back end, mai direttamente con il data agent o con ChromaDB.

Online i quattro servizi girano in un solo container, dietro nginx, unico punto esposto.

L'LLM COME SNODO DECISIONALE

Come l'assistente sceglie la strada

1. Solo numeri o grafici
→ analyze_data

2. Solo regole o metodologia
→ search_handbook

3. Entrambe le cose, chieste in modo esplicito
→ prima il manuale, poi i dati

4. Fuori ambito o saluto
→ nessuno strumento

```
> back-end@1.0.0 start
> node src/index.js

Back end in ascolto su http://localhost:3001
[tool] search_handbook {"query":"tempo di prima risposta per richieste ad alta priorità"}
[chat] sessione=763890d4 tool=[search_handbook] durata=5848ms esito=ok
[tool] analyze_data {"question":"Quali sono i 10 giocatori con il valore di mercato attuale più alt
o?","chart":true}
[chat] sessione=64083ee5 tool=[analyze_data] durata=14376ms esito=ok
[tool] search_handbook {"query":"metriche più importanti per i difensori centrali"}
[tool] analyze_data {"question":"Mostrami i 3 difensori centrali con il duels_won_pct attuale più a
lto.","chart":false}
[chat] sessione=fc6d4532 tool=[search_handbook,analyze_data] durata=9851ms esito=ok
```

Il log del back end durante la demo:

- SLA → solo il manuale
- Top 10 → solo i dati, con il grafico
- Difensori centrali → entrambi, in sequenza

Ciclo ReAct scritto a mano, al massimo 4 giri di scelta degli strumenti. Il data agent non vede la chat: riceve una domanda riscritta e completa.

DATI E KNOWLEDGE BASE

Due fonti costruite per essere coerenti

Il dataset delle osservazioni

1208 → 1185
righe, dopo aver tolto 23 duplicati

130
giocatori, identificati sempre da player_id

25
club, scritti in 74 modi diversi nel file grezzo

3
stagioni, dal 2023/24 al 2025/26

Pulizia deterministica nel codice, non affidata all'LLM: grafie dei club, date in formati misti, nomi in kanji, titoli nei nomi. Il riepilogo delle correzioni si può chiedere in chat.

Il manuale interno (knowledge base)

8
sezioni, da chi siamo alle FAQ

18
passaggi indicizzati in ChromaDB

È un file Markdown: testo semplice, i cui titoli servono a dividerlo in passaggi per la ricerca.

Allineato ai dati: la procedura di pulizia descritta nella sezione 6 è quella che il codice applica, e il glossario spiega le colonne del CSV.

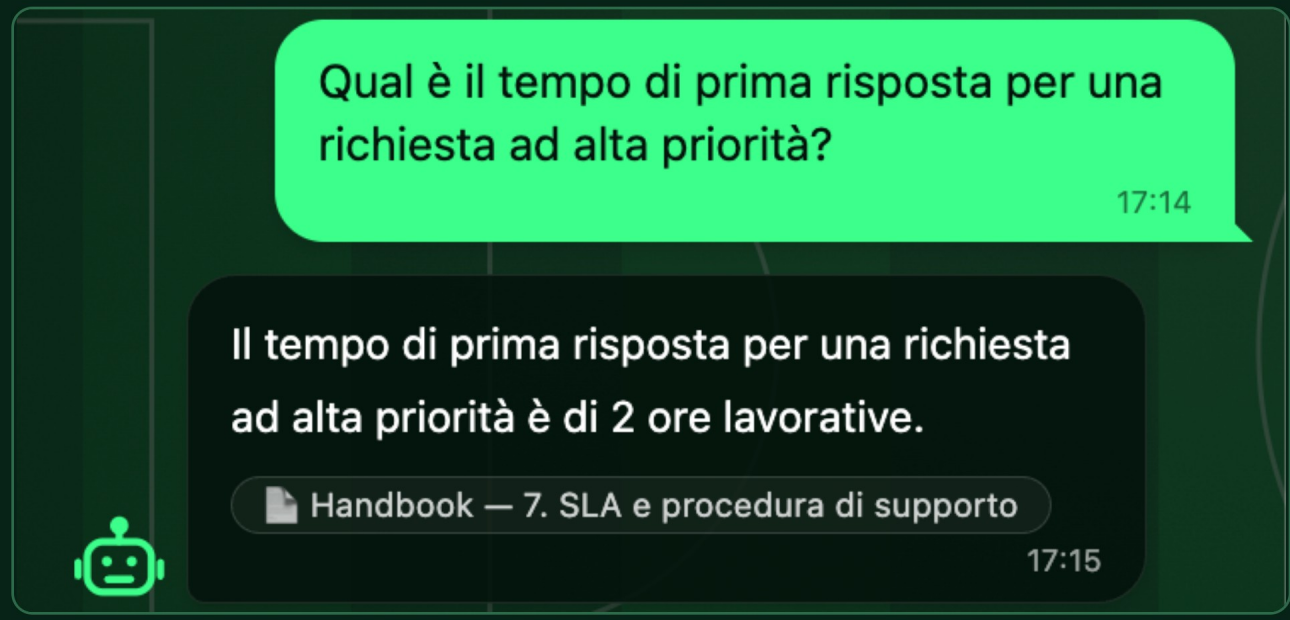
DEMO 1 · RISPOSTA DAL MANUALE

Per le regole, la risposta arriva dal manuale

1. L'LLM riconosce una domanda sulle procedure e chiama solo search_handbook.

2. ChromaDB trova i passaggi più vicini alla domanda; al modello arrivano solo quelli abbastanza pertinenti (distanza fino a 0,60 e vicina a quella del passaggio migliore).

3. La risposta è «2 ore lavorative»; sotto compare l'etichetta della sezione usata, «7. SLA e procedura di supporto».



DEMO 2 · ANALISI DEI DATI CON GRAFICO

Per i numeri, l'analisi passa al data agent

1. L'LLM chiama analyze_data e passa la richiesta del grafico come parametro (chart: true).

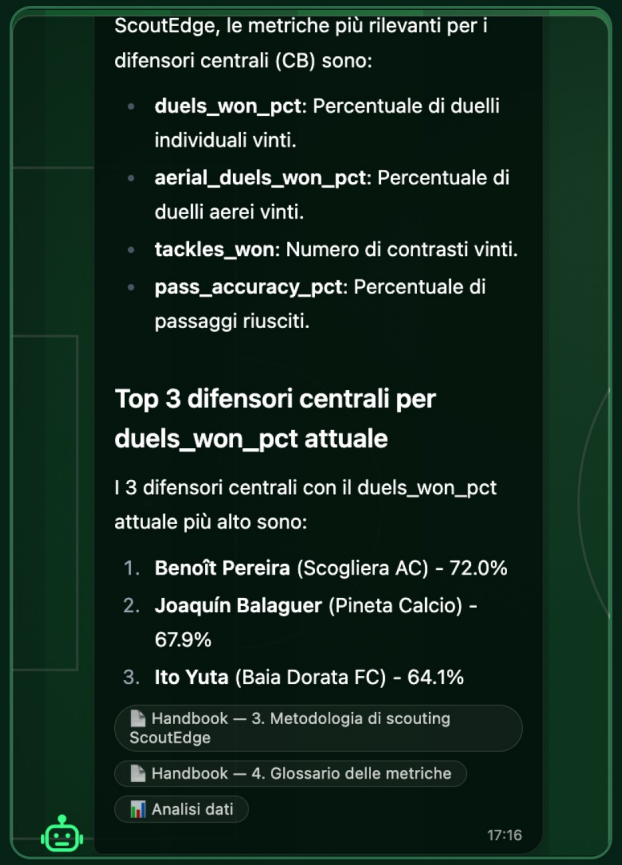
2. Il data agent scrive ed esegue codice pandas sul dataset già pulito e genera il grafico.

3. Al primo posto c'è il giocatore 5, Sato Jun, con 18.680.000 €. Il grafico compare nella risposta e nel pannello laterale, dove si può ingrandire o scaricare.



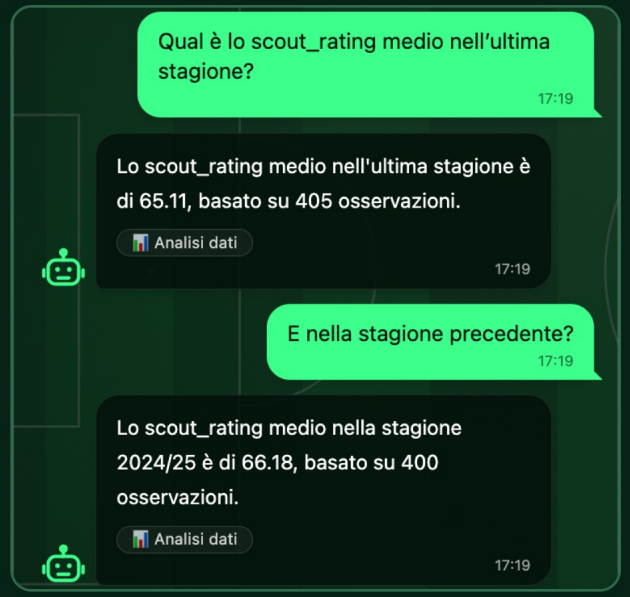
DEMO 3 · DOMANDA IBRIDA E MEMORIA

Una risposta con due strumenti e una chat che ricorda



Prima il manuale, poi i dati

Le metriche per i difensori centrali vengono dal manuale (sezioni 3 e 4); poi i dati indicano i 3 CB con il duels_won_pct attuale più alto: 120 Pereira (72,0), 122 Balaguer (67,9) e 6 Ito Yuta (64,1).



Memoria della conversazione

«E nella stagione precedente?» si capisce solo grazie alla domanda di prima: l'assistente la completa con la stagione 2024/25.

Risultati: 65,11 su 405 osservazioni nell'ultima stagione, poi 66,18 su 400.

SFIDE TECNICHE · 1 DI 3

Pulizia dei dati e calcoli corretti

Dati sporchi

COSA È EMERSO

74 grafie diverse per 25 club, nomi giapponesi in kanji e titoli come «Dr.» o «MBA» nei nomi di 12 giocatori (113 righe): questi ultimi sono emersi solo con una scansione completa del file.

SOLUZIONE

Pulizia deterministica nel codice, eseguita all'avvio, con controlli finali e un riepilogo delle correzioni che l'assistente può citare.

Una media sbagliata

COSA È EMERSO

Lo scout_rating medio dell'ultima stagione risultava 65,21 invece di 65,11: veniva calcolato sull'ultima osservazione di ogni giocatore (130 righe) e non sulle 405 della stagione.

SOLUZIONE

Il prompt distingue le domande su un periodo da quelle sullo stato attuale; il valore corretto è fissato nei test.

SFIDE TECNICHE · 2 DI 3

I grafici e l'integrazione tra agenti

Grafici lasciati al modello

COSA È EMERSO

Il modello salvava i grafici a modo suo e poteva annunciarne uno che non esisteva; gli assi dei valori di mercato comparivano in notazione 1e7.

SOLUZIONE

Il grafico si richiede con un parametro e viene salvato solo dallo strumento; la nota «grafico generato» è scritta dal codice; gli assi hanno i separatori delle migliaia.

Due agenti che non si capivano

COSA È EMERSO

Per la domanda sui giocatori 33 e 70, l'orchestratore scrive al data agent «giocatore con ID 70». Con questa forma il data agent saltava il controllo delle osservazioni nello stesso giorno: 19 risposte corrette su 33.

SOLUZIONE

La regola che attiva il controllo ora elenca anche le altre forme con cui si può indicare un giocatore: 30 risposte corrette su 30, senza regressioni sugli altri casi.

Il metodo: prima si traccia, poi si corregge

Prima di toccare il prompt, uno script mostra il codice eseguito dal data agent e l'output che ha ricevuto. Ogni giro di correzioni ha un criterio di arresto deciso in anticipo, e una modifica che peggiora altri casi viene tolta.

SFIDE TECNICHE · 3 DI 3

La scelta della piattaforma per la demo online

Piattaforma prevista a pagamento

Gli Space Docker di Hugging Face richiedono il piano PRO dall'8 luglio 2026. I piani gratuiti di altri servizi offrono 256–512 MB di memoria e poca CPU.

Prima misurare, poi scegliere

Il container in funzione usa tra 212 e 256 MB. Poi un piano gratuito simulato in locale (0,1 CPU, 512 MB), con la regola di decisione fissata prima della prova.

La decisione

Il collo di bottiglia è la CPU, non il codice: piano gratuito scartato. Scelta: Hugging Face PRO (9 $ al mese), con il container pronto in circa 20 secondi.

Avvio simulato: 2 minuti e 29 secondi, con `docker run --cpus=0.1 --memory=512m`



Indicizzazione 28 s

Data agent 91 s, di cui 79 s solo per caricare Python e le librerie

Back end 28 s

Chroma (1,7 s, il tratto chiaro iniziale) e nginx (0,5 s, quello finale) durano pochi istanti.

Sullo Space di Hugging Face (2 CPU): pronto in circa 20 secondi

TEST E AFFIDABILITÀ

Provato in locale, da un'installazione nuova e online

4 su 4
domande della demo, in locale dall'interfaccia

5 su 5
prove dell'interfaccia, vista da telefono compresa

3 su 3
prove con un servizio spento: nessun dato inventato

23 su 23
controlli automatici del contratto API, da zero

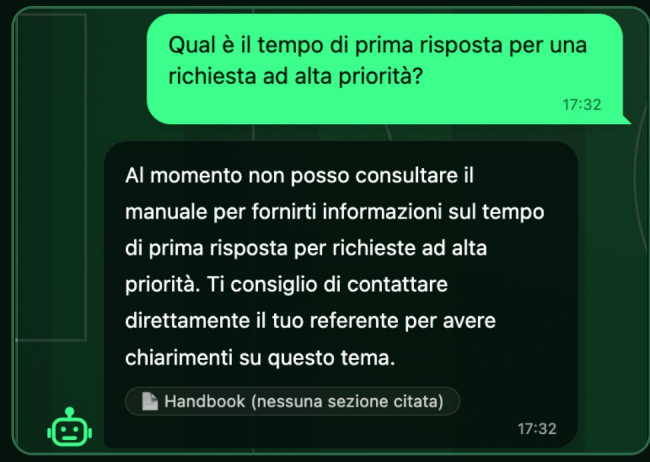
28 su 28
prove di regressione del data agent, da zero

0
chiavi API nei file del repository

4 su 4
domande della demo online, dal computer

4 su 4
domande della demo online, da un telefono Android

circa 20 s
per avere tutti i servizi pronti online



Con ChromaDB spento l'assistente dichiara che il manuale non è consultabile e non inventa la risposta.

Prova end-to-end il 18 ottobre 2026, installazione da un clone pulito il 19 ottobre, prove online il 26 ottobre.

SICUREZZA

Segreti protetti e difese a strati

Nessuna chiave nel codice

Le chiavi API stanno solo nei file .env, esclusi da git, o tra i secret dello Space; ogni servizio ha un .env.example senza valori. Verificato sul clone pulito.

La demo online

Un solo punto esposto

nginx serve l'interfaccia e inoltra al back end solo /api/ e /charts/; il resto risponde 404.

Limite di frequenza

20 richieste per IP e 100 in totale ogni 15 minuti, poi risposta 429.

IP vero del client

Ricavato con trust proxy e verificato: un indirizzo falsificato dal client viene ignorato.

Input

Messaggi fino a 2000 caratteri, richieste fino a 10 kb.

Rete

Data agent e ChromaDB solo in locale; il browser parla solo con il back end.

Tempi

Timeout di 90, 120 e 130 secondi sui tre tratti della richiesta.

Grafici

Nomi dei file validati in tre punti contro il path traversal.

Errori

Nessun dettaglio interno né valore di configurazione arriva al browser.

Interfaccia

Risposte mostrate senza HTML grezzo né immagini inserite nel testo.

LIMITI DICHIARATI

Limiti noti e cosa servirebbe in produzione

Il limite principale: la demo è protetta, ma il codice non ha una sandbox

Il data agent esegue codice Python scritto dall'LLM: una prompt injection ben costruita potrebbe diventare codice eseguito sulla macchina.

Online, il codice generato gira nello stesso processo che conosce la chiave OpenAI. Mitigazioni: chiave dedicata con un tetto di spesa mensile e revocabile in qualsiasi momento, limite di frequenza e una regola che vieta all'orchestratore di inoltrare codice agli strumenti (solo un primo filtro).

Altri limiti

- Risposte probabilistiche: alcune domande sui dati danno esiti variabili
- Importi nel testo in notazione anglosassone (18,680,000)
- Stagioni del dataset scritte nel prompt
- Sessioni in memoria, senza un tetto massimo

In produzione servirebbero

- Una sandbox isolata per eseguire il codice, senza rete né accesso al disco
- Autenticazione degli utenti
- Sessioni persistenti e con limiti

Il limite di frequenza della demo è una protezione di base: non sostituisce l'autenticazione.

IN SINTESI

Una chat, due fonti e un LLM che decide quale usare

Risposte dal manuale con la fonte citata, analisi dei dati con grafici e un sistema che dice chiaramente quando una fonte non è disponibile.

DEMO ONLINE

francodesc-scoutedge-analytics.hf.space

Dopo 48 ore senza visite la demo va in pausa: la prima apertura richiede circa 30 secondi.

REPOSITORY GITHUB

github.com/FranCodesc/scoutedge-analytics

Codice dei tre servizi, dataset e manuale, README con installazione, avvio e deploy, documentazione in docs/.